COMPILER PROJECT I: Lexical Analyzer

Documentation

20184690 장성현

1. Definition of tokens and their regular expressions

Some regular expressions in advance:
letter = A|B|C…|Y|Z|a|b|c|..|y|z *natural* = 1|2|3|4|5|6|7|8|9 *whitespace*= ₩n| |₩t

1-1. VTYPE

Definition) variable types.

Regular Expression) VTYPE = int | char | bool | float

1-2. INTEGER

Definition) integer variable.

Regular Expression) INTEGER = (-|ε)natural(0|natural)* | 0

1-3. LITERAL

Definition) literal variable.

Regular Expression) LITERAL = “(letter| |0|natural)* ”

1-4. BOOLEAN

Definition) Boolean variable.

Regular Expression) BOOLEAN = true | false

1-5. REAL

Definition) floating-point number variable.

Regular Expression)

REAL = (-|ε) (0|natural(0|natural)*). (0|(0|natural)* natural)

1-6. ID

Definition) an identifier.

Regular Expression) ID = (letter|_)(letter|0|natural_)*

1-7. KEYWORDS

Token Name	Definition	Regular Expression
IF	if for if statement	IF = if
ELSE	else for else statement	ELSE = else
WHILE	while for while-loop statement	WHILE = while
FOR	for for for-loop statement	FOR = for
RETURN	return for return statement	RETURN = return

1-8. OPERATORS

Token Name	Definition	Regular Expression
ARITHM	Arithmetic operators	ARITHM = +|-|*|/
BITWISE	Bitwise operators	BITWISE = <<|>>|&||
COMP	Comparison operators	COMP = <|>|==|!=|<=|>=
ASSIGN	Assignment operator	ASSIGN = =

1-9. SYMBOLS

Token Name	Definition	Regular Expression
SEMI	A terminating symbol of statements	SEMI = ;
LBRKT	A pair of symbols for defining area/scope of variables and functions	LBRKT = {
RBRKT		RBRKT = }
LPAREN	A pair of symbols for indicating a function/statement	LPAREN = (
RPAREN		RPAREN =)
COMMA	A symbol for separating input arguments in functions	COMMA = ,

2. DFA transition graph or table for recognizing the regular expressions

DFA transition table에서 노란색 표시는 Final State를 의미합니다.

2-1. VTYPE

VTYPE = int | char | bool | float

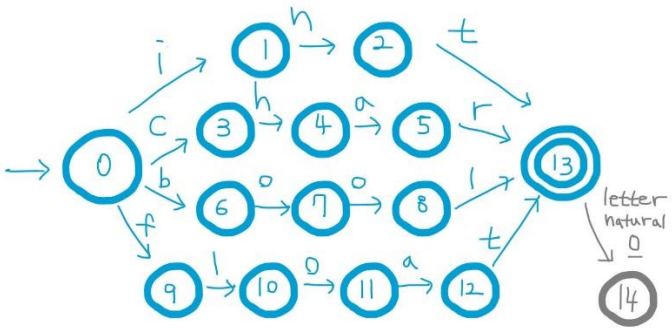

	i	n	t	c	h	a	r	b	o	l	f	letter	0	natural	_
T0	T1			T3				T6			T9				
T1		T2													
T2			T13												
T3					T4										
T4						T5									
T5							T13								
T6									T7						
T7									T8						
T8										T13					
T9										T10					
T10									T11						
T11						T12									
T12			T13												
T13												T14	T14	T14	T14
T14															

(빈칸은 모두 Φ)

2-2. INTEGER

INTEGER = (-|ε)natural(0|natural)* | 0

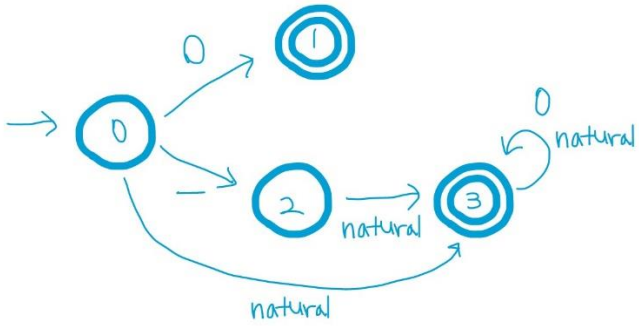

	0	-	natural
T0	T1	T2	T3
T1			
T2			T3
T3	T3		T3

(빈칸은 모두 Φ)

2-3. LITERAL

LITERAL = “(letter| |0|natural)* ”

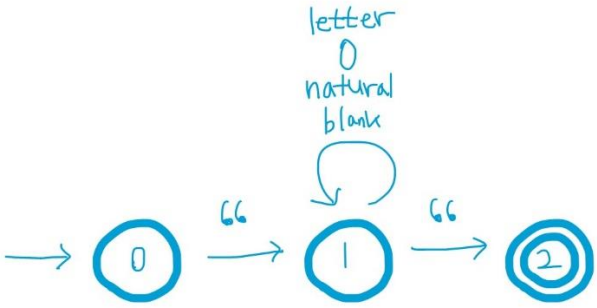

	“	letter	0	natural	blank
T0	T1				
T1	T2	T1	T1	T1	T1
T2					

(빈칸은 모두 Φ)

2-4. BOOLEAN

BOOLEAN = true | false

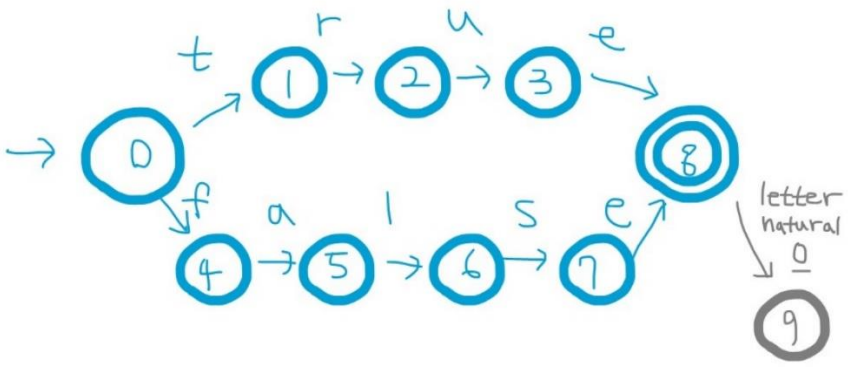

	t	r	u	e	f	a	l	s	letter	0	natural	_
T0	T1				T4							
T1		T2										
T2			T3									
T3				T8								
T4						T5						
T5							T6					
T6								T7				
T7				T8								
T8									T9	T9	T9	T9
T9												

(빈칸은 모두 Φ)

2-5. REAL

REAL = (-|ε) (0|natural(0|natural)*). (0|(0|natural)* natural)

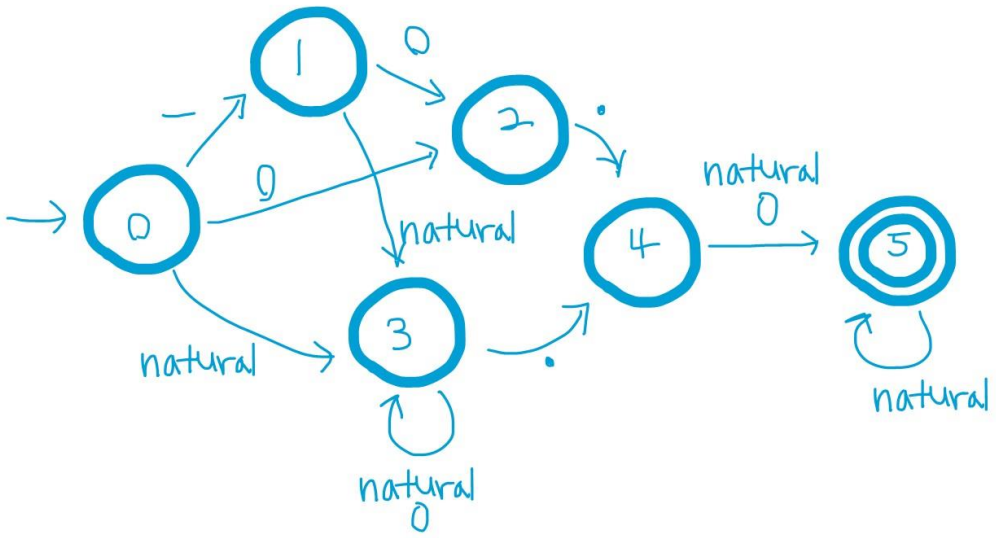

	-	0	natural	.
T0	T1	T2	T3	
T1		T2	T3	
T2				T4
T3		T3	T3	T4
T4		T5	T5	
T5		T6	T5	
T6		T6	T5	

(빈칸은 모두 Φ)

2-6. ID

ID = (letter|_)(letter|0|natural_)*

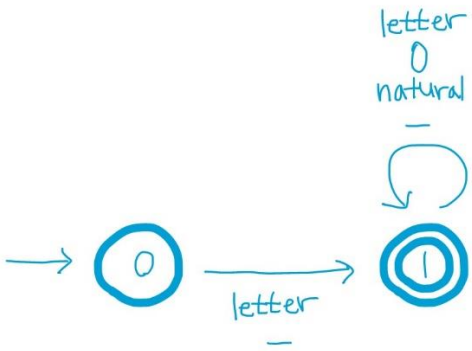

	letter	_	0	natural
T0	T1	T1		
T1	T1	T1	T1	T1

(빈칸은 모두 Φ)

2-7. KEYWORDS: IF ELSE WHILE FOR RETURN

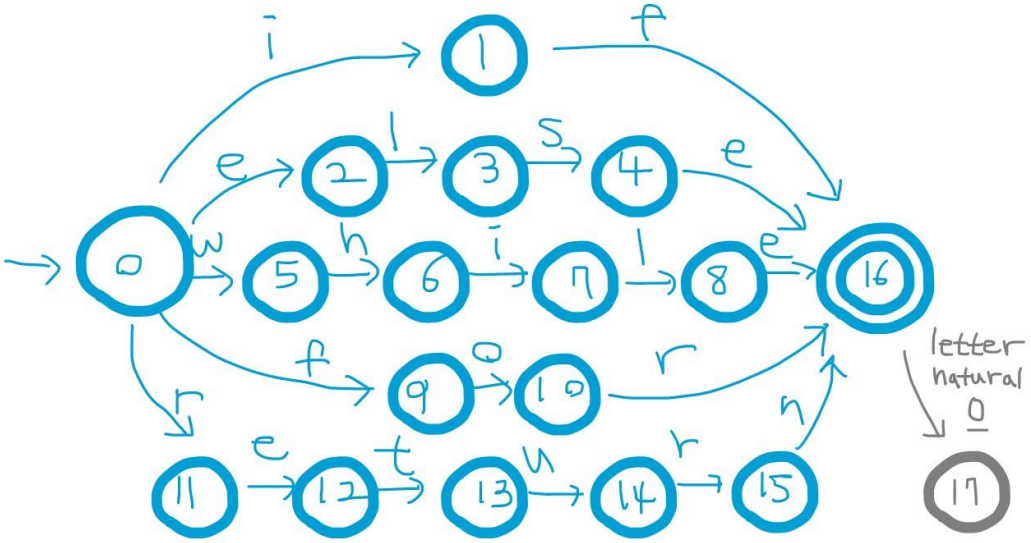

	i	f	e	l	s	w	h	o	r	t	u	n	letter	0	natural	_
T0	T1	T9	T2			T5			T11							
T1		T16														
T2				T3												
T3					T4											
T4			T16													
T5							T6									
T6	T7															
T7				T8												
T8			T16													
T9								T10								
T10									T16							
T11			T12													
T12										T13						
T13											T14					
T14									T15							
T15												T16				
T16													T17	T17	T17	T17
T17																

(빈칸은 모두 Φ)

2-8. OPERATORS: ARITHM BITWISE COMP ASSIGN

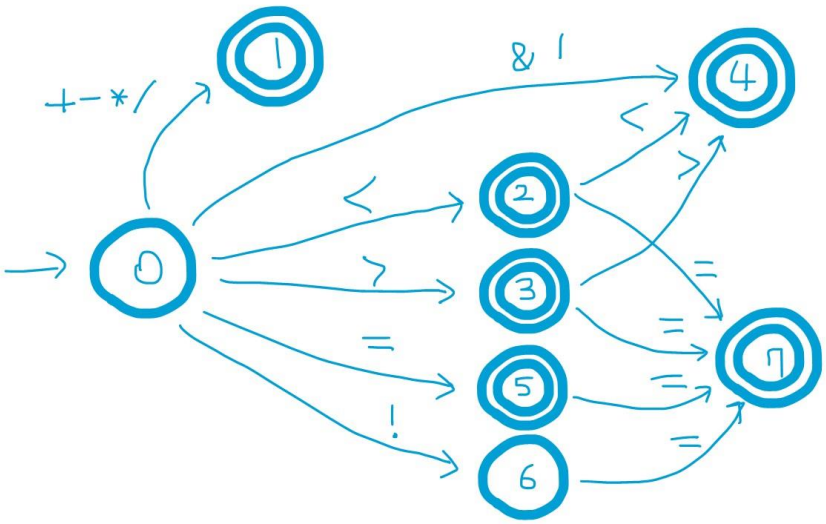

	+	-	*	/	&	|	<	>	=	!
T0	T1	T1	T1	T1	T4	T4	T2	T3	T5	T6
T1										
T2							T4		T7	
T3								T4	T7	
T4										
T5									T7	
T6									T7	
T7										

(빈칸은 모두 ϕ)

-각 Final State의 token 이름

T1: ARITHM

T4: BITWISE

T5: ASSIGN

T2, T3, T7: COMP

2-9. SYMBOLS: SEMI LBRKT RBRKT LPAREN RPAREN COMMA

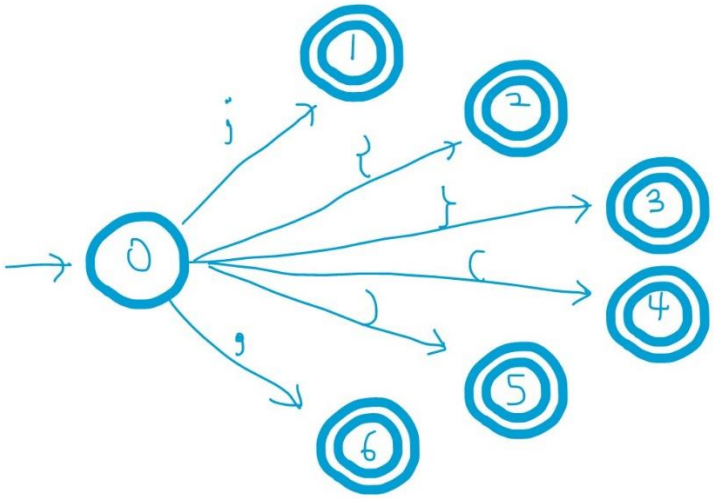

	;	{	}	(	)	,
T0	T1	T2	T3	T4	T5	T6
T1						
T2						

T3						
T4						
T5						
T6						

(빈칸은 모두 Φ)

-각 Final State의 token 이름

T1: SEMI

T2: LBKRT

T3: RBKRT

T4: LPAREN

T5: RPAREN

T6: COMMA

3. How lexical analyzer works for recognizing tokens

3-1. Overall Procedures

- 입력 파일로부터 한 글자를 읽은 후, 다음과 같은 10가지 함수를 이용해 token을 분류합니다. (이 중 isWHITESPACE만 symbol table을 생성하지 않고 스킵합니다)

isWHITESPACE
isSYMBOL
isVTYPE
isKEYWORD
isBOOLEAN
isLITERAL
isREAL
isINTEGER
isOPERATOR
isID

- 각 함수는 token을 분류하면 true를 반환하는데, 10개 함수를 모두 통과하고도 true인 적이 없다면 에러를 output파일에 출력하고 중단합니다.

-에러가 발생한 경우 기존에 작성하던 symbol table이 있으면 그 파일을 지우고 다시 output파일을 만들어서 에러문구만 출력합니다.
-token은 아니지만 하나의 regular expression인 letter와 natural(자연수)도 각각 isletter() isnatural() 이라는 참 거짓 여부를 반환하는 함수를 만들었습니다.

3-2. Implementation Details

Algorithms

- 10개의 is~함수 중에서 주의할 우선순위는 다음과 같습니다:

isREAL > isINTEGER
(예: 51.6 => isINTEGER를 먼저 하면 51을 integer로 분류하고 .에서 에러가 발생합니다)

isINTEGER > isOPERATOR
(예: -1 => isOPERATOR를 먼저 하면 -를 operator로 분류하고 1을 integer로 분류하는 문제가 발생합니다)

isVTYPE > isID
(예: int => isID를 먼저 하면 int를 identifier로 분류하는 문제가 발생합니다)

isKEYWORD > isID
(예: if => isID를 먼저 하면 if를 identifier로 분류하는 문제가 발생합니다)

isBOOLEAN > isID
(예: true => isID를 먼저 하면 true를 identifier로 분류하는 문제가 발생합니다)

interesting과 같이 처음은 vtype(혹은 keyword, Boolean)에 분류될 수 있는데 뒤에 글자가 더 있는 경우 즉, **isID > isVTYPE** 와 같은 우선순위를 띄어야 하는 경우 id로 분류하기 위해, DFA table에서 회색 처리된 부분과 같이 non-final state를 하나씩 추가함으로써 이 문제를 해결했습니다.

-각 10개의 is~함수는 거의 동일한 형식으로 구성되어 있습니다.

-위의 DFA Table에 맞게 state가 바뀌도록 IF-ELSE 구문들이 적혀 있습니다. 더 이상 input에 따라 바꿀 수 있는 State가 없는 경우가 될 때까지 이것을 반복합니다.

-마지막에 도달한 State가 Final State라면 classifier 함수를, 아니면 rewinder 함수를 작동하게 됩니다.

-classifier 함수는 output파일에 symbol table의 한 행을 작성합니다. rewinder 함수는 token 분류가 안된 마지막 위치로 되돌아갑니다. Read를 할 때 ngets라는 변수의 값을 1씩 증가시키는데, rewinder 함수는 ngets만큼 파일 포인터 위치를 되감습니다.

-isWHITESPACE 함수는 input이 '₩n'인 걸 판단할 때 변수 linenumber를 1 증가시켜 에러가 났을 때 몇 번째 줄에서 에러가 난 건지 알 수 있습니다.

Data Structures

- 전역변수: char **attribute[]**

글자를 읽을 때 이 배열에 저장해두어 나중에 classifier 함수에서 symbol table의 attribute부분을 적을 때 가져오게끔 구현하였습니다. 이 배열은 한 번만 선언해서 재사용합니다.

키워드로 분류된 경우 symbol table의 오른쪽 부분은 비우고, 배열 attribute[]의 내용을 대문자화하여 symbol table의 왼쪽에 출력합니다.

- (10개의 is~함수에서 각각 쓰는) 지역변수: int **state**

현재 어떤 state에 있는지는 int 형식으로 저장합니다.

3-3. Working Examples

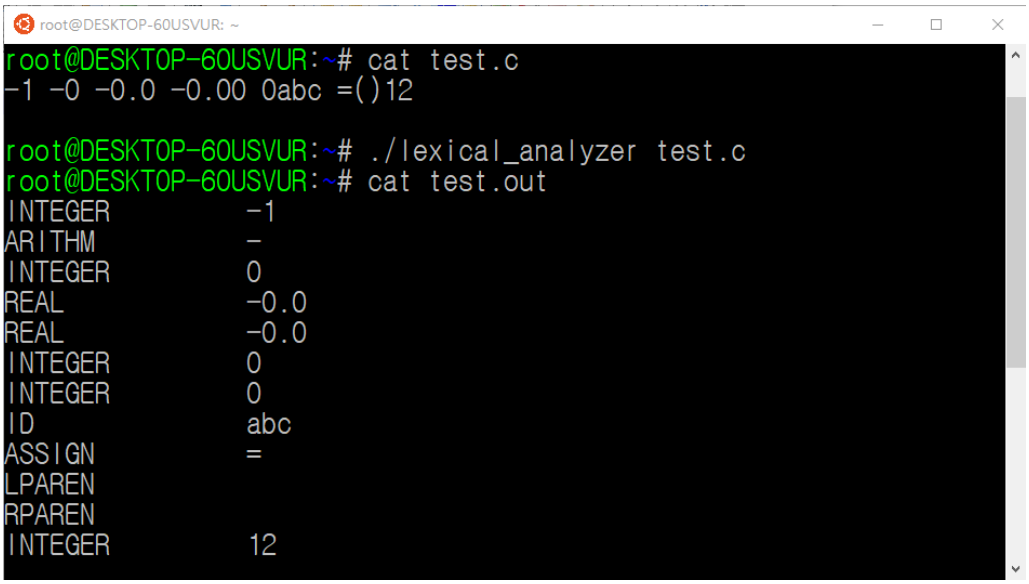

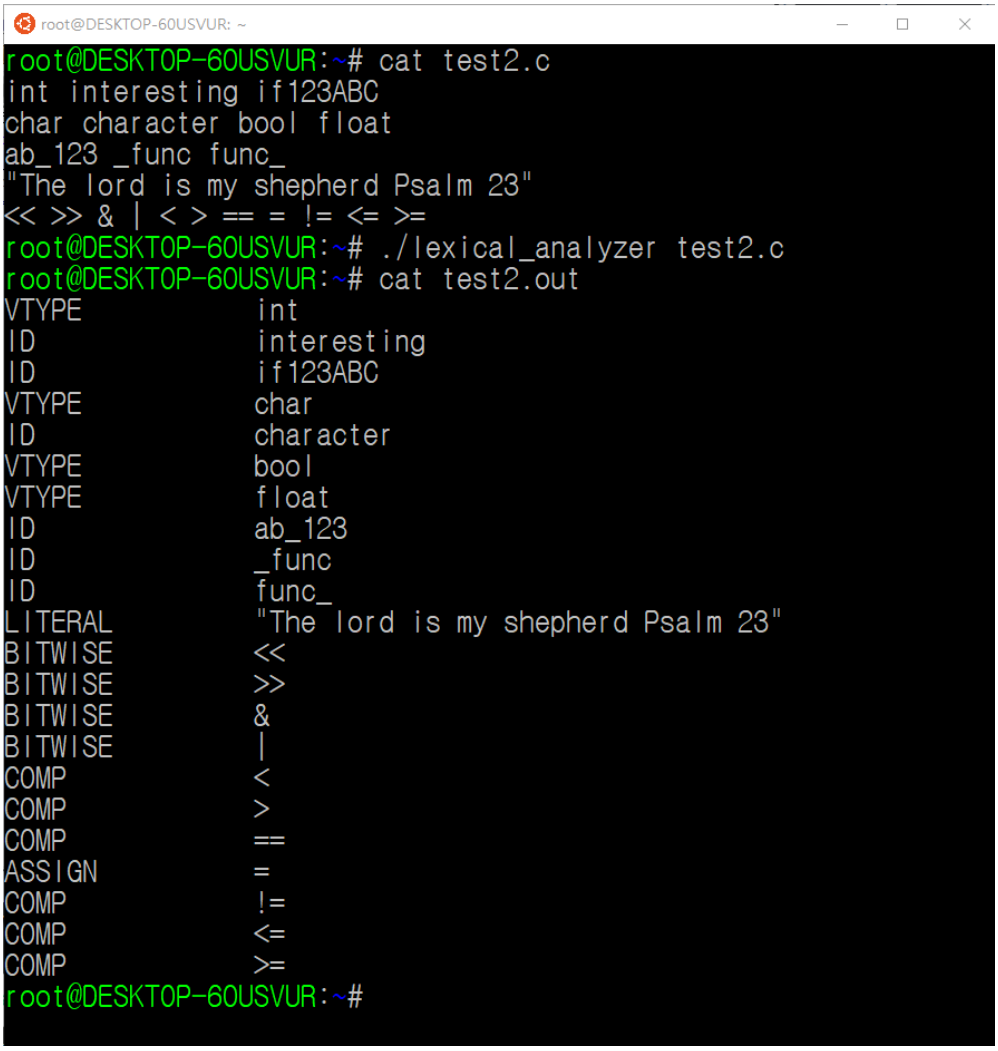

```
root@DESKTOP-60USVUR:~# cat test3.c
while(true)
{
        a = b + c;
        sum = sum + 52 / 2 * 4 - 2;
        answer = 23.15 - 24.0;
}
for(int i = 0; i <123; i++)
        if else return false;

root@DESKTOP-60USVUR:~# ./lexical_analyzer test3.c
root@DESKTOP-60USVUR:~#
```

```
 1 WHILE
 2 LPAREN
 3 BOOLEAN     true
 4 RPAREN
 5 LBKRT
 6 ID      a
 7 ASSIGN      =
 8 ID      b
 9 ARITHM      +
10 ID      c
11 SEMI
12 ID      sum
13 ASSIGN      =
14 ID      sum
15 ARITHM      +
16 INTEGER     52
17 ARITHM      /
18 INTEGER     2
19 ARITHM      *
20 INTEGER     4
21 ARITHM      -
22 INTEGER     2
23 SEMI
24 ID      answer
25 ASSIGN      =
26 REAL        23.15
27 ARITHM      -
28 REAL        24.0
29 SEMI
30 RBKRT
1:1 [Top]                                   ~/test3.outW
```

<= test3.out vim 화면(상)

```
31 FOR
32 LPAREN
33 VTYPE       int
34 ID      i
35 ASSIGN      =
36 INTEGER     0
37 SEMI
38 ID      i
39 COMP        <
40 INTEGER     123
41 SEMI
42 ID      i
43 ARITHM      +
44 ARITHM      +
45 RPAREN
46 IF
47 ELSE
48 RETURN
49 BOOLEAN     false
50 SEMI
50:1 [Bot]                                  ~/test3.outW
```

<= test3.out vim 화면(하)

에러 발생 예시

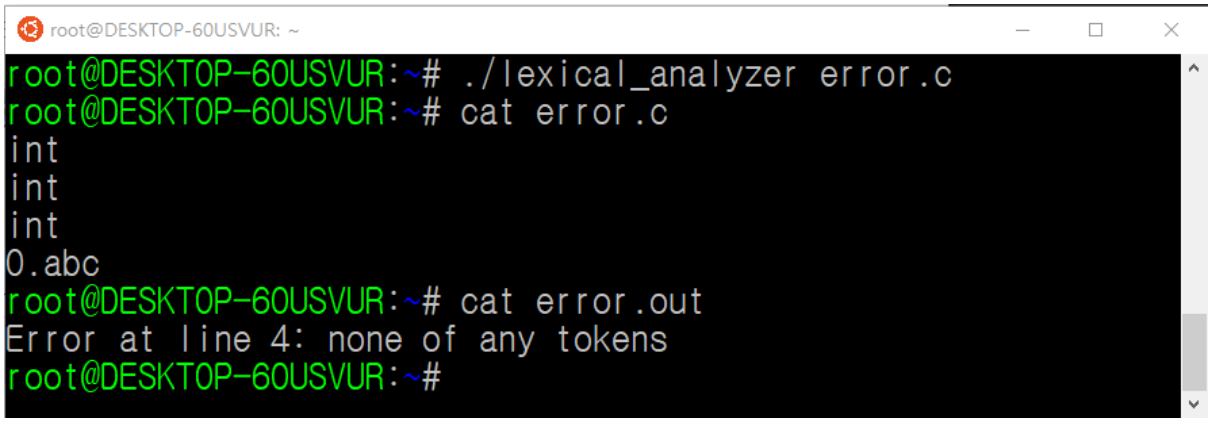
root@DESKTOP-60USVUR: ~
root@DESKTOP-60USVUR:~# ./lexical_analyzer error.c
root@DESKTOP-60USVUR:~# cat error.c
int
int
int
0.abc
root@DESKTOP-60USVUR:~# cat error.out
Error at line 4: none of any tokens
root@DESKTOP-60USVUR:~#

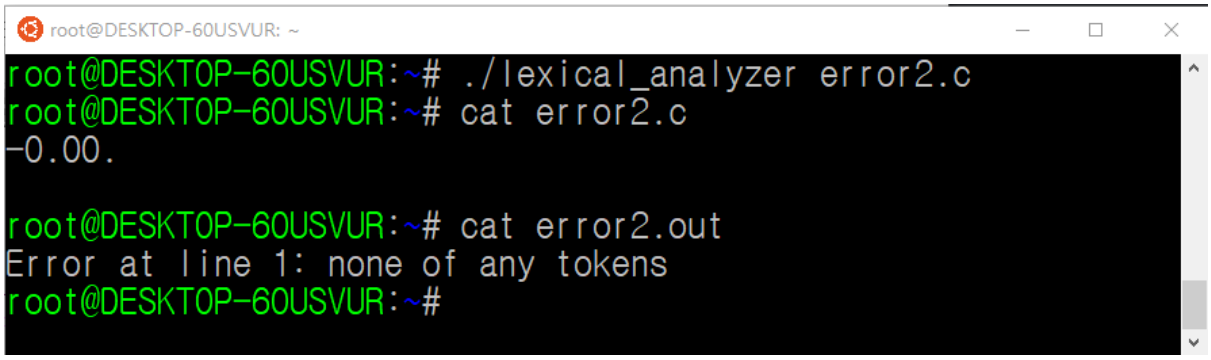
root@DESKTOP-60USVUR: ~
root@DESKTOP-60USVUR:~# ./lexical_analyzer error2.c
root@DESKTOP-60USVUR:~# cat error2.c
-0.00.
root@DESKTOP-60USVUR:~# cat error2.out
Error at line 1: none of any tokens
root@DESKTOP-60USVUR:~#

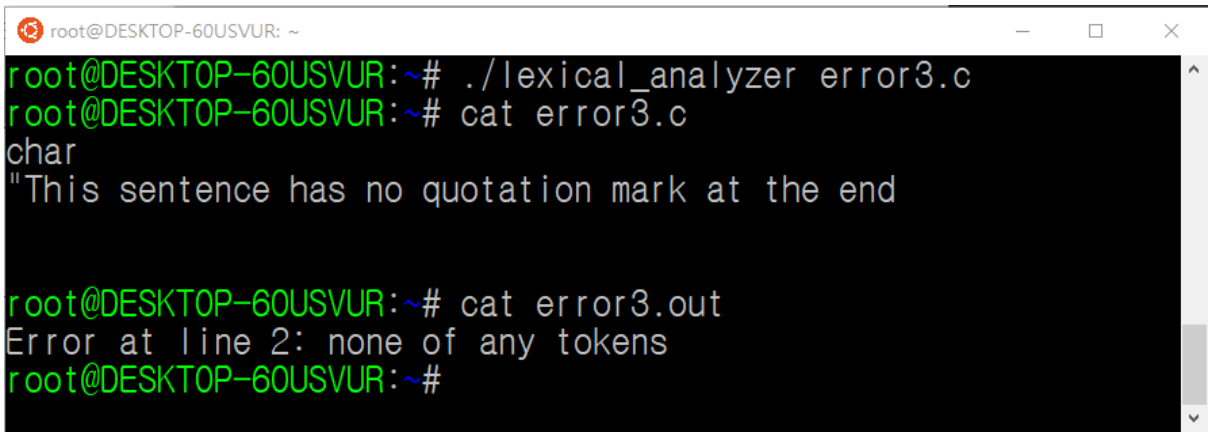
root@DESKTOP-60USVUR: ~
root@DESKTOP-60USVUR:~# ./lexical_analyzer error3.c
root@DESKTOP-60USVUR:~# cat error3.c
char
"This sentence has no quotation mark at the end
root@DESKTOP-60USVUR:~# cat error3.out
Error at line 2: none of any tokens
root@DESKTOP-60USVUR:~#